

사하구청 AI 상담사

2026년 9월 29일 작업 결과 보고서

오늘은 Supabase 마이그레이션부터 실제 증분 크롤링, 검색 데이터 복구, Ollama 상담 검증, 환각 방지 보완, 시스템 상태 화면 확인까지 전체 흐름을 점검했습니다. 현재 핵심 구성요소는 모두 정상이며 외부 LLM API 키 없이 로컬 Ollama로 동작합니다.

핵심 결과

511	1,438	0	25 / 25
수집 원문	검색 청크 / 벡터	누락·고아 벡터	자동 테스트 통과

최종 상태 한눈에 보기

구성요소	상태	확인 내용
웹 API	정상	메인 상담 화면과 시스템 상태 화면 HTTP 200
로컬 AI	정상	Ollama qwen2.5:1.5b 연결 및 실제 답변 생성
검색 인덱스	정상	청크 1,438건 = 벡터 1,438건, 불일치 0건
작업 큐	정상	대기 0건, 실패 0건, 성공 61건
개인정보	보호	신규 대화 영구 저장 안 함, 익명 DB 조회 차단

1. 오늘 적용한 주요 변경

영역	문제 또는 목표	적용 내용	결과
Supabase	작업 큐와 실행 이력 테이블 필요	마이그레이션 적용, RLS와 익명 권한 차단 검증	운영 이력과 실패 상태 확인 가능
증분 크롤링	변경된 페이지만 다시 처리	실제 사하소개 메뉴 재실행	신규 13, 수정 17, 변경 없음 119
장애 안전성	처리 실패 전에 기존 벡터가 삭제됨	새 청크 생성·임베딩 성공 후 오래된 데이터만 정리하도록 순서 변경	중간 장애에도 기존 검색 데이터 보존
데이터 복구	첫 실행 실패로 검색 청크 누락	원문에서 누락 청크 387개 재생성·임베딩	누락 0, 고아 0
Ollama	예전 LangChain import 경로로 서버 초기화 실패	langchain-ollama 공식 통합 경로 적용	외부 API 키 없이 정상 작동
응답 속도	청크 1건도 배치 요청 후 재시도	1건은 처음부터 단건 프롬프트 사용	불필요한 Ollama 호출 감소
답변 완성도	220토큰에서 답변이 중간 종료	기본 생성 길이를 384토큰으로 상향	짧고 완결된 행정 안내

쉽게 설명하면

예전에는 새 데이터를 만드는 도중 오류가 나면 기존 검색 자료까지 먼저 없어질 수 있었습니다. 지금은 새 검색 자료가 완성된 것을 확인한 다음 오래된 자료만 정리합니다. 또한 AI가 담당 부서를 추측하지 못하도록 홈페이지 원문에 실제로 적힌 부서만 사용합니다.

2. 환각 현상과 출처 정확성 보완

발표 피드백의 핵심이었던 환각 문제를 검색 전·검색 후·답변 후의 세 단계에서 막도록 보완했습니다.

단계	보호 장치	동작 방식
질문 입력	모호성 확인	규격에 따라 금액이 달라지는 질문은 바로 단정하지 않고 필요한 정보를 되묻습니다.
검색 결과	공식 출처 게이트	사하구 공식 도메인과 질문 관련성이 확인된 자료만 답변 근거로 사용합니다.
답변 생성	근거 부족 시 보류	근거가 부족하면 LLM 호출을 생략하고 정확한 정보를 찾지 못했다고 안내합니다.
부서·연락처	원문 검증	AI가 추측한 부서는 제거하고 페이지의 담당자 표기와 공식 직원 안내만 사용합니다.
개인정보	입출력 차단	민감정보 입력을 감지해 저장하지 않고, 답변에 섞인 개인정보 패턴은 마스킹합니다.

실제 멀티턴 테스트

사용자	고우니 AI
침대 배출 수수료가 얼마야?	침대 종류와 규격에 따라 달라요. 돌침대/일반침대, 1인용/2인용, 매트리스 단독 여부를 알려주세요.
일반침대 2인용이야.	일반침대 2인용의 배출 수수료는 18,000원입니다.

검증 결과: 금액은 사하구청 '대형폐기물 처리 및 수수료안내' 원문과 일치했고, 출처 URL·담당 부서(자원순환과)·연락처도 함께 반환됐습니다.

3. 검증 결과와 현재 운영 상태

검증 항목	결과	확인 내용
마이그레이션	통과	crawl_runs, ingestion_jobs, last_checked_at 활성화
RLS 보안	통과	conversation_logs, crawl_runs, ingestion_jobs 익명 SELECT 차단
벡터 정합성	통과	processed_chunks 1,438 = documents 1,438
부서 메타데이터	통과	원문 기반 1,044건 보정 후 잔여 변경 대상 0건
기능·안전 테스트	통과	환각, 출처, 개인정보, 멀티턴, 하이브리드 검색 등 25개 테스트
UI 최종 확인	통과	웹 API 정상, Ollama 연결, 벡터 1,438, 큐 실패 0 표시

운영 시 알아둘 점

- 현재 상담 답변과 자동 태깅은 로컬 Ollama를 사용하므로 OpenAI 등 외부 LLM API 키가 없어도 동작합니다.
- Hugging Face 토큰은 다운로드 속도 제한을 완화하는 선택 사항이며 현재 실행에는 필수가 아닙니다.
- 과거 대화 로그 718건은 RLS로 보호되어 있습니다. 삭제는 데이터 파괴 작업이므로 이번 작업에서는 보존했습니다.
- 신규 대화는 기본 설정에서 데이터베이스에 영구 저장하지 않고 서버 메모리에서만 문맥을 유지합니다.
- 시스템 상태는 웹 화면의 '시스템 상태' 링크에서 바로 확인할 수 있습니다.

최종 결론: 데이터 수집 - 자동 태깅 - 하이브리드 검색 - Ollama 답변 - 공식 출처 제공 - 개인정보 보호까지 핵심 흐름이 연결되어 있으며, 오늘 발견된 장애 복구와 환각 방지 문제도 반영했습니다.